

Treniranje i evaluacija klasifikacionog modela

Treniranje modela za klasifikaciju preloma kostiju izvršeno je u *Google Colab* okruženju, uz korišćenje GPU akceleracije. Kao biblioteka za rad sa modelima korišćen je Ultralytics YOLO framework, koji podržava klasifikacione modele zasnovane na YOLO arhitekturi.

Prvo je instalirana potrebna biblioteka:

```
!pip install ultralytics
```

Dataset je prethodno pripremljen u ZIP formatu i postavljen na *Google Drive*. Nakon povezivanja *Google Drive* prostora sa *Colab* okruženjem:

```
from google.colab import drive  
drive.mount('/content/drive')
```

dataset je kopiran u lokalni prostor *Colab* okruženja:

```
!cp "/content/drive/MyDrive/dataset.zip" /content/
```

Provera uspešnog kopiranja izvršena je komandom:

```
!ls -l /content/dataset.zip
```

Nakon toga dataset je raspakovan:

```
!unzip /content/dataset.zip
```

Struktura dataseta korišćena za treniranje bila je:

```
Bone_Fracture_Binary_Classification/  
|  
| — train/  
|   | — fractured/  
|   | — not fractured/  
|  
| — val/  
|   | — fractured/  
|   | — not fractured/  
|  
| — test/  
|   | — fractured/  
|   | — not fractured/
```

Dataset sadrži dve klase:

- **fractured** – rendgenski snimci na kojima postoji prelom
- **not fractured** – rendgenski snimci bez preloma

Za klasifikaciju je korišćen unapred trenirani model **YOLO11n-cls**:

```
from ultralytics import YOLO

model = YOLO('yolo11n-cls.pt')
```

Korišćen je *transfer learning* pristup, gde se model prethodno treniran na velikom skupu podataka dodatno prilagođava specifičnom problemu klasifikacije preloma.

Treniranje modela izvršeno je sledećom komandom:

```
results = model.train(
    data='/content/dataset/Bone_Fracture_Binary_Classification',
    epochs=30,
    imgsz=256
)
```

Parametri treninga:

- **epochs=30** – model je treniran kroz 30 prolaza kroz ceo trening skup podataka.
- **imgsz=256** – ulazne slike su skalirane na rezoluciju 256×256 piksela.
- **data** – putanja do dataseta.


Dataset je sadržao:

- **trening skup**: 9246 slika
- **validacioni skup**: 829 slika
- **test skup**: 506 slika

Tokom učitavanja podataka, ugrađeni validacioni mehanizam Ultralytics biblioteke detektovao je nekoliko oštećenih datoteka uz obaveštenje: **ignoring corrupt image/label**. Ukupno je zanemaren zanemarljivo mali broj neispravnih fajlova, što je osiguralo stabilnost procesa bez ručne predistraživačke analize, dok je ostatak dataseta uspešno iskorišćen za treniranje.

Tokom treninga korišćen je napredni optimizator AdamW, koji je automatski alociran od strane framework-a kao optimalno rešenje.

Analiza toka treninga i rezultata



Slika 1. Grafički prikaz metrika performansi modela kroz epohe

Model je uspješno treniran svih 30 epoha. Tokom treninga gubitak (*loss*) se konstantno smanjivao, što pokazuje da je model uspješno učio karakteristike rendgenskih snimaka.

Rezultati kroz epohe:

Epoha	Training loss	Validation accuracy	Validation loss
1	0.36806	90.77%	0.22120
10	0.05841	96.72%	0.09475
20	0.02765	97.81%	0.05958
30	0.00935	99.27%	0.02422

Gubitak na treningu konstantno opada sa početnih **0.36806** na izuzetno niskih **0.00935** u posljednjoj epohi. Nisu uočeni jasni indikatori overfitting-a, pošto se validacioni loss tokom treninga nastavio smanjivati, pa se pretpostavlja da je model uspješno generalizovao ključne geometrijske i teksturalne karakteristike preloma sa rendgenskih snimaka.


Nakon završetka treninga, težine modela su sačuvane u:

- `/content/runs/classify/train/weights/best.pt` (model sa najboljim performansama na validacionom skupu)
- `/content/runs/classify/train/weights/last.pt` (model iz poslednje epohe)

Završna evaluacija najboljeg modela (`best.pt`) na validacionom skupu dala je sledeće metričke vrednosti:

- `top1_acc = 0.99271` (odnosno **99.27%**)
- `top5_acc = 1.0` (odnosno **100%**)

Napomena o metrikama: Dobijena *Top-1* tačnost od 99.27% znači da je model u preko 99% slučajeva iz prve tačno odredio klasu snimka. Vrednost *Top-5* tačnosti iznosi očekivanih 1.0 (100%), s obzirom na to da je reč o binarnoj klasifikaciji (ukupno 2 klase), te prošireni izbor top 5 najverovatnijih klasa po prirodi stvari uvek obuhvata tačan odgovor.



Slika 2 Matrica konfuzije

Analizom generisane matrice konfuzije na validacionom skupu podataka dobija se uvid u raspodelu tačnih i pogrešnih klasifikacija po klasama:

- **Klasa `fractured` (Prelom):** Model pokazuje izuzetnu osetljivost (skoro stoprocentnu tačnost), gde uspešno prepoznaje realne prelome sa minimalnim procentom lažno negativnih rezultata (propuštenih preloma), što je kritično važna stavka u medicinskoj dijagnostici.

- **Klasa not fractured (Bez preloma):** Specifičnost modela je takođe na visokom nivou. Broj lažno pozitivnih ishoda (gde je zdrav nokat/kost proglašen prelomom) sveden je na zanemarljivu meru.

Izbalansiranost normalizovane matrice konfuzije potvrđuje da visoka ukupna tačnost nije posledica debalansa klasa u datasetu, već stvarne sposobnosti neuronske mreže da diferencira patologiju na snimcima.

Brzina izvršavanja modela nakon treniranja bila je:

- preprocess: 0.2 ms
- inference: 0.8 ms

što pokazuje da model ima veoma kratko vreme predikcije i da bi mogao biti pogodan za primenu u sistemima gde je potrebna brza klasifikacija rendgenskih snimaka.

Prelazak na lokalno okruženje i izvoz modela (ONNX format)

Nakon završetka treninga izvršena je provera redosleda klasa koje model koristi prilikom klasifikacije. Ovo je važno zbog kasnije implementacije inferencije pomoću OpenCV DNN modula, jer izlaz modela predstavlja verovatnoće klasa u istom redosledu kojim su klase definisane tokom treninga.

Provera je izvršena učitavanjem najboljeg modela:

```
from ultralytics import YOLO

model = YOLO('/content/runs/classify/train/weights/best.pt')
print(model.names)
```

Na osnovu dobijenog rezultata utvrđeno je da indeks **0** odgovara klasi **fractured**, dok indeks **1** odgovara klasi **not fractured**. Ovaj redosled klasa je korišćen prilikom dalje implementacije inferencije u OpenCV okruženju, gde se izlaz neuronske mreže mapira na odgovarajuću klasifikacionu oznaku.

Kako bi se izbegao gubitak modela usled resetovanja ili prekida *Google Colab* sesije, nakon završetka treniranja izvršeno je kopiranje svih rezultata na *Google Drive*. Za to je korišćena komanda:

```
!cp -r /content/runs /content/drive/MyDrive/
```

Na ovaj način sačuvani su trenirani modeli, grafikoni i svi prateći rezultati treninga. Nakon kopiranja izvršena je provera lokacije najboljeg modela komandom:

```
!find /content/drive/MyDrive/runs -name "best.pt"
```

Komanda je omogućila pronalaženje datoteke `best.pt`, koja predstavlja model sa najboljim rezultatima tokom treniranja i koja je korišćena za dalju evaluaciju i inferenciju.

Najbolji model je preuzet sa *Google Drive*-a na lokalnu mašinu radi dalje integracije sa računarskim vidom u realnom vremenu pomoću biblioteke **OpenCV**.

Sa ciljem optimizacije performansi, smanjenja vremena inferencije i obezbeđivanja nezavisnosti od specifičnih *PyTorch* zavisnosti u produkcionom kodu, izvršena je konverzija (izvoz) modela u univerzalni **ONNX (Open Neural Network Exchange) format**. Zbog toga je kreirana `export.py` skripta:

```
from ultralytics import YOLO  
  
model = YOLO('model/best.pt')  
model.export(format="onnx")
```

Nakon izvršenja ove skripte, u istom folderu kreira se fajl **best.onnx**. To je konačna verzija modela koja je spremna za učitavanje u lokalne skripte i brzu analizu rendgenskih snimaka pomoću OpenCV-ja.

Učitavanje i inferencija ONNX modela pomoću OpenCV DNN modula

Za svaku test sliku izvršeno je učitavanje pomoću OpenCV biblioteke, normalizacija ulaznih podataka i promena dimenzija slike na 256×256 piksela, nakon čega je izvršena inferencija pomoću ONNX modela.

Ukupno je testirano 506 rendgenskih snimaka:

- 235 slika klase **fractured**
- 271 slika klase **not fractured**

Dobijeni rezultati:

- Ukupan broj slika: **506**
- Tačno klasifikovane slike: **501**
- Pogrešno klasifikovane slike: **5**
- Accuracy: **99.01%**

Matrica konfuzije:

	Predicted fractured	Predicted not fractured
True fractured	234	4
True not fractured	1	267

Model je uspešno prepoznao 234 od 238 snimaka sa prelomom, dok je samo jedan snimak bez preloma pogrešno klasifikovan kao prelom. Dobijeni rezultati potvrđuju da se performanse modela nisu značajno promenile nakon konverzije u ONNX format i implementacije pomoću OpenCV biblioteke.

Dodavanje potencijalnih poboljšanja upotrebom OpenCV radi podizanja tačnosti

Kao dodatni korak optimizacije izvršiće se ispitivanje uticaja različitih tehnika pretprocesiranja rendgenskih snimaka korišćenjem OpenCV biblioteke. Cilj ovih metoda je poboljšanje kvaliteta ulaznih podataka i potencijalno povećanje tačnosti klasifikacionog modela.

Biće testirane sledeće tehnike:

- **CLAHE (Contrast Limited Adaptive Histogram Equalization)** – metoda za lokalno poboljšanje kontrasta slike primenom adaptivnog izjednačavanja histograma.
- **Unsharp masking** – tehnika oštrenja slike zasnovana na oduzimanju zamućene verzije slike od originala radi naglašavanja ivica i detalja.
- **Normalizacija intenziteta** – linearno preslikavanje vrednosti intenziteta piksela u puni opseg [0,255] radi ujednačavanja kontrasta između različitih snimaka.
- **Median blur** – nelinearni filter za uklanjanje šuma koji pri tome čuva ivice objekata.
- **Normalizacija sa blagim oštrenjem (Norm + Sharp)** – kombinacija normalizacije intenziteta i unsharp masking tehnike sa manjim stepenom oštrenja.
- **Histogram equalization** – globalno izjednačavanje histograma sa ciljem povećanja ukupnog kontrasta slike.

Radi vizuelnog poređenja uticaja različitih metoda pretprocesiranja, na slici 3 je prikazan primer istog rendgenskog snimka nakon primene svih testiranih tehnika. Može se uočiti da metode menjaju kontrast, nivo detalja i izraženost ivica, dok struktura same slike ostaje očuvana.



Slika 3 Vizuelni prikaz svih korišćenih tehnika pretprocesiranja

Za svaku tehniku izvršena je inferencija nad kompletnim test skupom od 506 rendgenskih snimaka, nakon čega su izračunate vrednosti accuracy, true positive (TP), false positive (FP), true negative (TN) i false negative (FN).

Dobijeni rezultati prikazani su u tabeli:

Metoda	Accuracy	TP	FP	TN	FN
Bez pretprocesiranja	99.01%	234	1	267	4
CLAHE	98.42%	238	8	260	0
Unsharp masking	98.22%	234	5	263	4
Normalizacija	99.80%	238	1	267	0
Median blur	99.01%	234	1	267	4
Norm + Sharp	99.80%	238	1	267	0
Histogram equalization	98.02%	234	6	262	4

Rezultati pokazuju da nisu sve tehnike pretprocesiranja dovele do poboljšanja performansi modela. CLAHE je uspešno eliminisao lažno negativne klasifikacije (FN = 0), odnosno model nije propustio nijedan prelom, ali je istovremeno značajno povećao broj lažno pozitivnih rezultata, što je dovelo do pada ukupne tačnosti.

Unsharp masking i histogram equalization pokazali su još slabije rezultate, uz povećanje broja lažno pozitivnih klasifikacija i smanjenje ukupne tačnosti modela. Median blur nije imao primetan uticaj na performanse, pa su rezultati ostali identični osnovnom modelu bez pretprocesiranja.

Najbolje rezultate ostvarile su metode **normalizacije intenziteta** i **normalizacije sa blagim oštrenjem**, koje su postigle tačnost od 99.80%. Kod obe metode broj lažno negativnih klasifikacija smanjen je sa 4 na 0, dok je broj lažno pozitivnih rezultata ostao nepromenjen. Time je broj tačno klasifikovanih snimaka povećan sa 501 na 505 od ukupno 506 testiranih slika.

Na osnovu dobijenih rezultata može se zaključiti da je normalizacija intenziteta najefikasnija tehnika pretprocesiranja za korišćeni skup rendgenskih snimaka. Ova metoda uspešno ujednačava kontrast između različitih snimaka i omogućava modelu pouzdanije izdvajanje karakteristika koje ukazuju na prisustvo preloma kostiju.